SuperMimic 精读笔记

Humanoid 控制、策略梯度与世界模型

Humanoid whole-body control / PPO / Differentiable MBRL

hikaru

写在前面

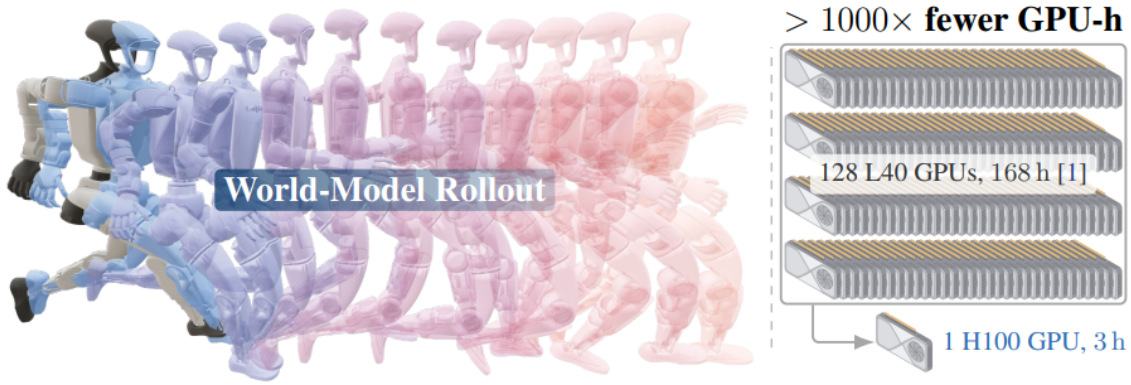
SuperMimic 是 UC Berkeley 的 Qiayuan Liao 等人发表于 CoRL 2026 的工作。[1]

Humanoid 全身控制希望让同一台机器人稳定地执行走、跑、跳乃至翻滚等多种运动。人类动作提供了丰富的行为样本，机器人还需要根据实际姿态、速度和接触情况调整关节指令。如何把动作数据变成能在真实身体上运行的反馈控制器，是这些工作共同面对的问题。

围绕这一问题，以 SONIC 为代表的 model-free RL（MFRL）已经形成了一条成熟路线：在大规模仿真中采样，用运动跟踪奖励训练策略。[8] Model-based RL（MBRL）则尝试学习动作之后身体怎样变化，再利用这个模型优化策略。同一身体执行不同运动时，学到的动力学可以反复用于训练；模型还能够提供动作影响未来的局部梯度。这让 MBRL 在训练效率上很有吸引力，也引出了模型误差、接触与长期求导等困难。

SuperMimic 沿着这条路线，把共享动力学、短时优化与长期价值估计用于大规模 humanoid 控制。读懂它，也就有机会重新理解 MBRL 为什么自然、为什么难，以及怎样在这个任务上做得好。借一句玩笑话，可谓 *Make MBRL Great Again*。

这篇笔记从 humanoid 控制的技术积累出发，沿同一个长期回报目标推导 PPO 与 BPTT，理解二者的优化性质与 MBRL 遇到的困难。随后回到 SuperMimic，学习模型拟合、短时 actor–critic、数据覆盖和部署接口的设计，再结合原论文实验理解训练效率与恢复行为。最后讨论这里的身体动力学模型，与机器人操作任务中的外部世界模型有什么联系。



SuperMimic 原论文图 1。一个共享的可微世界模型用于训练多技能全身控制策略。[1]

2026 年 10 月

目录

1 两条策略训练路线 **3**

2 MFRL **4**
2.1 累计回报与策略目标 . . . 4
2.2 策略梯度与 advantage . . . 4
2.3 TRPO 与 PPO . . . 5
2.4 策略梯度的训练性质 . . . 6

3 MBRL **6**
3.1 动力学模型与策略优化 . . . 6
3.2 闭环 BPTT . . . 7
3.3 物理延迟与信用分配 . . . 8

4 BPTT 分析 **9**
4.1 模型误差与导数误差 . . . 9
4.2 长程 Jacobian 与梯度传播 . . . 11
4.3 接触阈值与梯度估计 . . . 11
4.4 数据覆盖与探索 . . . 13

5 SuperMimic **13**
5.1 交替训练与经验回放 . . . 13
5.2 世界模型与多步监督 . . . 14
5.3 短时展开与终点价值 . . . 15
5.4 终止风险与生存权重 . . . 16
5.5 Critic 与多步回报 . . . 16
5.6 数据采样与部署接口 . . . 17

6 效果 **18**
6.1 训练效率与动作规模 . . . 18
6.2 时域消融与推扰恢复 . . . 18
6.3 G1 实机控制 . . . 19

7 复现 **20**

8 Action World 与 WAM **20**

A 符号与训练接口 **21**

参考文献 **22**

1 两条策略训练路线

在 Humanoid 全身运动控制中，目前主要有两条策略训练路线。Model-free RL（MFRL）通过物理仿真采集轨迹，根据回报更新策略，PPO 是其中最常见的方法。Model-based RL（MBRL）则尝试学习机器人的动力学模型，再利用模型预测运动，并通过动力学反向传播来优化策略。两者解决的是同一个问题：如何将人类运动数据转化为能够在真实机器人上执行的反馈控制器。

这一任务的发展离不开动作数据、物理仿真和真机部署等方面的积累。DeepMimic 较早展示了如何利用运动捕捉数据和强化学习训练模仿策略。[2] 后续的 H2O 解决人体动作向机器人重定向与可执行性筛选的问题，ASAP 通过真机数据修正仿真中的动力学差异，Hold My Beer 研究上下肢不同控制目标与频率的协调，BeyondMimic 则进一步改善多种高动态动作的跟踪与部署。[4, 5, 6, 7] 与此同时，GPU 并行仿真大幅加快了 PPO 的训练。[3] 这些进展逐渐使大规模动作库的学习与真实执行成为可能。

SONIC 是这条发展过程中的一个重要转折点。它同时扩大动作数据、网络容量和训练计算，训练出能够覆盖广泛运动的单个通用跟踪器。[8] 这说明以 PPO 为代表的 MFRL 已经能够处理大规模 Humanoid Motion Tracking，也使它成为这一任务上非常有竞争力的主流方案。不过，这种规模化依然需要昂贵的训练成本。SuperMimic 所比较的 SONIC 已发布模型使用 128 张 L40 训练 168 小时，约合 2.15 万 GPU-hours。[1] 当动作库扩展到数百小时，如何提高策略训练的计算效率，就成了一个值得重新考虑的问题。

另一条 MBRL 路线其实也一直在发展。早在 2021 年，SuperTrack 就尝试从模拟器转移中学习可微动力学，通过模型展开和反向传播训练动作跟踪器。[9] 后来的 SuperDyno 将这一思路扩展到更大的动作库。[10] 与 PPO 主要利用采样回报估计策略梯度不同，这些工作希望进一步利用每次状态转移中的动力学信息，直接计算动作变化对未来回报的影响。

SuperMimic 延续了这条路线，将共享的可微动力学模型、短时策略优化和价值函数结合，用于大规模 G1 全身动作跟踪。[1] 因此，理解 SuperMimic 的关键之一，就是理解 PPO 与可微动力学究竟如何使用同一段运动轨迹，以及两种梯度更新各有什么优势和困难。下面从共同的累计回报目标出发，分别推导 PPO 与 BPTT。

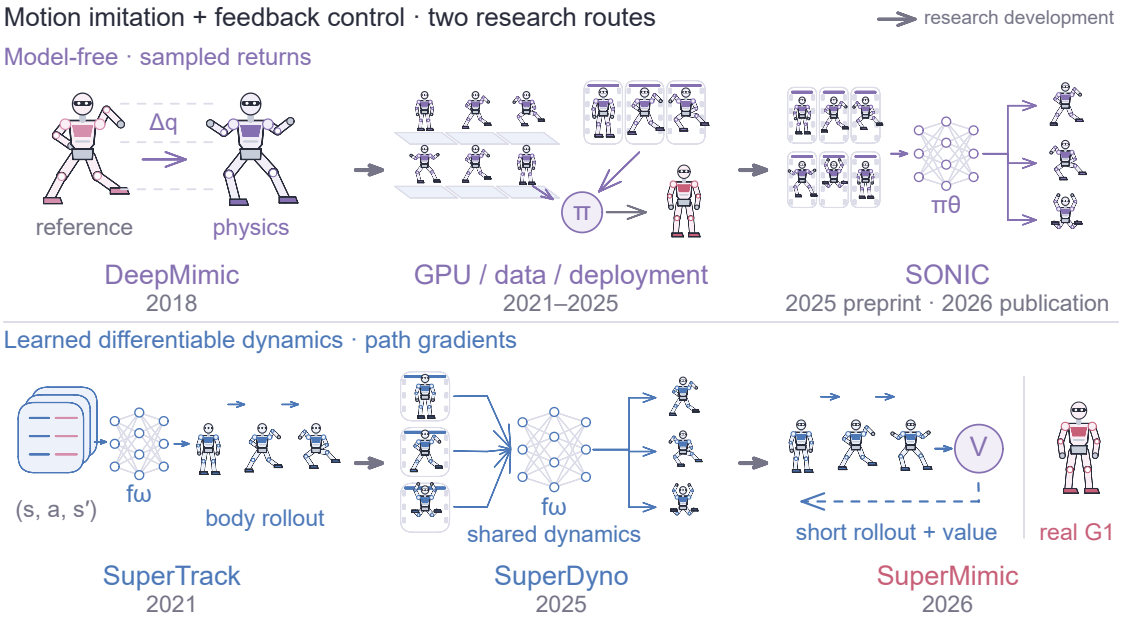


图 1 动作模仿的两条研究路线。粗灰箭头连接路线发展，细彩色箭头表示局部数据与预测关系；上路以采样回报学习控制，下路学习可微动力学并使用路径梯度。

2 MFRL

前面的 motion tracking 任务，最终需要把参考动作、平衡与恢复这些要求变成策略的训练信号。MFRL 的做法是让机器人在模拟器中尝试动作，根据整段运动的回报调整策略。以 PPO 为例，我们先从它优化的目标出发，看每一步动作怎样接收到长期评价，以及这条统计路径为什么适合大规模仿真训练。

2.1 累计回报与策略目标

跟踪误差可以逐步计入奖励，落地或跌倒的后果则可能在许多步之后才出现。把这些评价放在一起，策略优化的目标就是整个运动过程的累计回报。设 s_t 为环境状态，a_t 为动作，$r_{t+1} = r(s_t, a_t, s_{t+1})$ 为执行动作后的奖励，$\gamma \in [0, 1)$ 为折扣。策略参数为 θ，环境转移为 P。这里的状态包含目标信息与预测后续所需的历史；有限时域下也包含时刻。策略希望最大化

$$J(\theta) = \mathbb{E}_{\tau \sim p_\theta}[R(\tau)], \qquad R(\tau) = \sum_{t=0}^{T-1} \gamma^t r_{t+1}. \tag{2.1}$$

轨迹 $\tau = (s_0, a_0, s_1, \ldots, s_T)$ 的概率分解为

$$p_\theta(\tau) = p_0(s_0) \prod_{t=0}^{T-1} \underbrace{\pi_\theta(a_t \mid s_t)}_{\text{策略选择动作}} \underbrace{P(s_{t+1} \mid s_t, a_t)}_{\text{环境产生后果}}.$$

这里 P 可以来自刚体物理模拟器。策略参数影响动作的采样概率，并通过动作改变后续状态的分布。

策略决定怎样尝试动作，模拟器给出这些尝试的后果。以连续控制中常见的高斯策略为例，网络输出 $\mu_\theta(s)$ 与 $\sigma_\theta(s)$，它们定义 $\pi_\theta(a \mid s)$；动作再从这个分布中采样。每次执行会得到一条轨迹与一个累计回报，因此可以用多次交互的平均值估计目标。对 N 条独立轨迹，经验均值

$$\widehat{J}_N = \frac{1}{N} \sum_{i=1}^{N} R(\tau^{(i)})$$

在回报可积时依大数定律收敛到 J；有限方差时，其方差为 $\mathrm{Var}(R)/N$。策略网络给出了动作的概率分布，采样则让我们估计这个分布在环境中产生的实际回报。

2.2 策略梯度与 advantage

有了回报样本，下一步是把它变成参数更新方向。策略梯度从轨迹出现的概率入手：高回报轨迹中的动作应当更容易被选中，低回报轨迹中的动作则相反。利用恒等式 $\nabla p = p \nabla \log p$，将目标求导：

$$\nabla_\theta J = \int R(\tau)\, \nabla_\theta p_\theta(\tau)\, d\tau \tag{2.2}$$

$$= \mathbb{E}_{p_\theta}\left[R(\tau) \nabla_\theta \log p_\theta(\tau)\right] \tag{2.3}$$

$$= \mathbb{E}_{p_\theta}\left[R(\tau) \sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t)\right]. \tag{2.4}$$

最后一步来自环境转移对 θ 没有显式依赖：轨迹的 log probability 中，只有策略项需要求导。碰撞、摩擦和落地的影响已经体现在采样回报里，优化时计算的是策略网络怎样改变这些动作的概率。

整条轨迹的回报还混合了动作 a_t 之前和之后的结果。由于这个动作只能影响之后的奖励，把奖励按时间拆开，过去回报与当前 score 项的乘积期望为零，便得到 reward-to-go 形式

$$\nabla_\theta J = \mathbb{E}\sum_{t=0}^{T-1}\gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t)\, G_t, \quad G_t = \sum_{k=t}^{T-1}\gamma^{k-t} r_{k+1}. \tag{2.5}$$

G_t 的条件期望是动作价值 $Q^\pi(s_t, a_t)$。不过，当前状态本身就可能使所有动作都得到较高或较低的回报。为了更清楚地评价当前动作带来的改善，可以减去一个只依赖状态的 baseline $b(s_t)$。这不会改变梯度的期望，因为

$$\mathbb{E}_{a\sim\pi(\cdot|s)}[b(s)\nabla_\theta \log \pi_\theta(a \mid s)] = b(s)\nabla_\theta \int \pi_\theta(a \mid s)\, da = 0.$$

状态价值 $V^\pi(s_t)$ 表示从当前状态出发、按当前策略继续行动时的平均累计回报；减去这个平均值，就能评价选中动作比通常的后续表现好多少。取 $b = V^\pi$，便得到 advantage $A^\pi = Q^\pi - V^\pi$ 及策略梯度

$$\nabla_\theta J = \mathbb{E}\sum_t \gamma^t \; \nabla_\theta \log \pi_\theta(a_t \mid s_t) \;\; A^\pi(s_t, a_t)\,. \tag{2.6}$$

蓝色项给出提高当前采样动作概率的参数方向；紫色 advantage 的正负决定沿这个方向还是反方向更新，大小则为更新加权。这个评价可以包含很远以后的落地、恢复或任务成功。

例如起跳后两秒才出现落地奖励，G_t 仍将这项奖励带回起跳动作。奖励跨越时间的方式，是进入 return 和 advantage；参数梯度本身沿策略网络反传。这个结构解释了 model-free 策略梯度怎样使用长期结果。[11, 12]

2.3 TRPO 与 PPO

上述梯度是在当前策略的轨迹分布下计算的。实际训练希望一批采样支持多次更新，而第一次更新后，策略就已经发生变化。要继续使用这批数据，需要描述新旧策略对同一个动作赋予的概率差异。记采集数据的策略为 π_{old}，新策略为 π_θ，单步概率比为

$$\rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{old}}(a_t \mid s_t)}.$$

在同一状态下，importance sampling 将对新动作分布的期望改写为旧动作分布下的加权期望：

$$\mathbb{E}_{a\sim\pi_\theta}[A_{\text{old}}(s,a)] = \mathbb{E}_{a\sim\pi_{\text{old}}}[\rho(\theta)A_{\text{old}}(s,a)].$$

单步概率比处理的是同一状态下动作分布的变化；连续控制还要考虑新策略会把机器人带到哪些状态。无限时域下，令 $d^\pi(s) = (1-\gamma)\sum_{t\ge 0}\gamma^t P(s_t = s \mid \pi)$，performance difference identity 给出

$$J(\theta) - J(\text{old}) = \frac{1}{1-\gamma}\mathbb{E}_{s\sim d^{\pi_\theta},\, a\sim\pi_\theta}[A_{\text{old}}(s,a)].$$

以 $d^{\pi_{\text{old}}}$ 近似更新后的状态分布，便得到局部 surrogate。TRPO 在优化这个 surrogate 时，限制新旧策略的平均 KL 距离：

$$\begin{aligned} \max_\theta \quad & \mathbb{E}_{\text{old}}[\rho_t(\theta)\widehat{A}_t], \\ \text{s.t.} \quad & \mathbb{E}_{s\sim d^{\pi_{\text{old}}}}\left[D_{\text{KL}}(\pi_{\text{old}}(\cdot \mid s)\|\pi_\theta(\cdot \mid s))\right] \le \delta. \end{aligned} \tag{2.7}$$

更新幅度受到约束时，旧数据对新策略的评价更有用。PPO 将这一更新控制写成便于 minibatch 优化的 clipped objective：

$$L^{\text{clip}}(\theta) = \mathbb{E}_{\text{old}}\left[\min\left(\rho_t\widehat{A}_t, \text{clip}(\rho_t, 1-\varepsilon, 1+\varepsilon)\widehat{A}_t\right)\right]. \tag{2.8}$$

当 $\widehat{A}_t > 0$，该样本希望提高动作概率；$\rho_t > 1+\varepsilon$ 后，继续提高概率不再增加其 clipped 收益。当 $\widehat{A}_t < 0$，该样本希望降低动作概率；$\rho_t < 1-\varepsilon$ 后，相应收益同样变平。由此削弱对旧样本过度优化的动力，并允许多轮 minibatch 更新。clip 操作作用在优化收益上。[12]

这样，同一批轨迹既提供各步动作的长期评价，也能支持多轮 minibatch 优化；clipped objective 用来控制反复利用旧样本时的更新幅度。

2.4 策略梯度的训练性质

式 (2.6) 把策略更新分为“概率变化方向”与“回报评价”。物理后果通过样本回报进入评价，所以接触切换、终止阈值等环境事件可以直接影响动作概率。随机策略还会采到当前均值之外的动作。若一个有用行为每次出现的概率为 p，N 次独立尝试至少观察到一次的概率是 $1-(1-p)^N$。

这条路径也适合利用 GPU 仿真：不同环境可以同时采集轨迹，策略更新从大量回报样本中估计方向；baseline、估计状态价值的网络（critic）和 advantage estimation 则帮助减少统计波动。长期结果通过 advantage 进入更新，策略网络的反传也不需要穿过整段物理过程。

总结以上讨论，PPO 的主要性质有以下三点：

1. **并行效率**。多个仿真环境可以同时采集轨迹，策略更新无需沿整段物理动力学反传，适合大规模 GPU 仿真训练。
2. **训练稳定性**。baseline 与 critic 有助于降低梯度估计的波动，clip 抑制对旧样本的过度优化，使策略能够较稳定地迭代。
3. **探索与长期评价**。随机策略能够尝试当前均值之外的动作，advantage 则将后续回报带入当前动作的评价。

与此同时，每一个方向仍要从动作尝试与回报差异中辨认。高维动作包含许多变化，远期回报又混合了中间各步的影响。MBRL 尝试利用模拟器中共同的身体动力学规律，直接计算动作变化对回报的影响，从每条轨迹中获得更具体的优化方向。

3 MBRL

PPO 通过重复尝试，统计哪些动作变化伴随着更高回报。如果能预测身体在动作之后怎样运动，并对这个预测求导，我们就可以沿着动作、状态和奖励之间的关系直接计算改进方向。这是可微 MBRL 提高训练效率的出发点：用模型复用已收集的转移经验，再让一次 rollout 提供局部方向信息。

3.1 动力学模型与策略优化

要得到这条可微路径，首先需要一个能够预测下一状态的模型。考虑确定性控制器 $a_t = \mu_\theta(s_t)$。从模拟器收集状态、动作及下一状态，学习

$$\hat{s}_{t+1} = f_\omega(\hat{s}_t, a_t),$$

其中 ω 是动力学模型参数，θ 是策略参数。模型训练改变 ω，使预测接近模拟器；策略训练暂时固定 ω，使模型内回报提高。两个优化问题使用同一批交互经验，但目标和求导变量各自明确。

模型拟合后，就可以在模型内试运行控制器。令 H 为本次显式展开的长度。从记录的状态

$\hat{s}_0 = s_0$ 出发，模型与策略轮流执行：

$$\hat{s}_0 \xrightarrow{\mu_\theta} a_0 \xrightarrow{f_\omega} \hat{s}_1 \xrightarrow{\mu_\theta} a_1 \xrightarrow{f_\omega} \cdots \xrightarrow{f_\omega} \hat{s}_H.$$

先只累加这 H 步的模型奖励，得到一个窗口内目标；当 H 短于完整运动时，窗口之后的回报还需要另外接续。当前窗口内的 imagined objective 为：

$$\hat{J}_H(\theta) = \mathbb{E}_{s_0}\left[\sum_{t=0}^{H-1} \gamma^t \hat{r}_{t+1}\right], \qquad \hat{r}_{t+1} = r_\omega(\hat{s}_t, a_t). \tag{3.1}$$

PPO 与模型内策略优化都追求运动的累计回报，当前写出的模型目标计算的是显式窗口内的部分。策略参数通过每一步动作影响后续状态，对这张时间展开的图应用链式法则，就得到 backpropagation through time，即 BPTT。模型的状态预测让 rollout 能继续，局部 Jacobian 则告诉策略怎样改变动作。SVG、SuperTrack 等工作都利用了这类可微路径。[14, 9]

3.2 闭环 BPTT

为了看清一个参数的变化怎样传到未来，先记下每一步状态对策略参数的总导数。设状态、动作和参数的维数分别为 n, m, p。定义

$$D_t = \frac{d\hat{s}_t}{d\theta} \in \mathbb{R}^{n\times p}, \quad f_{s,t} = \frac{\partial f_\omega}{\partial s} \in \mathbb{R}^{n\times n}, \quad f_{a,t} = \frac{\partial f_\omega}{\partial a} \in \mathbb{R}^{n\times m},$$

$$\mu_{s,t} = \frac{\partial \mu_\theta}{\partial s} \in \mathbb{R}^{m\times n}, \qquad \mu_{\theta,t} = \frac{\partial \mu_\theta}{\partial \theta} \in \mathbb{R}^{m\times p}.$$

所有偏导均在当前轨迹的状态与动作处取值。本节标量函数对向量的偏导按行 Jacobian 记，其转置给出参数的列梯度。策略参数有两条路径改变 a_t：直接改变策略输出，以及先改变此前状态、再经策略反馈改变动作。因此

$$\frac{da_t}{d\theta} = \mu_{s,t} D_t + \mu_{\theta,t}.$$

将它代入状态转移的导数，得到

$$\begin{aligned} D_{t+1} &= f_{s,t} D_t + f_{a,t} \frac{da_t}{d\theta} \\ &= \left(f_{s,t} + f_{a,t}\mu_{s,t}\right) D_t + f_{a,t}\mu_{\theta,t}. \end{aligned} \tag{3.2}$$

记 $F_t = f_{s,t} + f_{a,t}\mu_{s,t}$，$B_t = f_{a,t}\mu_{\theta,t}$。$F_t$ 是闭环状态传播：f_s 描述状态直接怎样传到下一步，$f_a\mu_s$ 描述状态通过控制器改变动作后怎样传到下一步。B_t 则是本步策略参数向动力学注入的新影响。

数据起点对本轮参数固定，故 $D_0 = 0$。反复展开递推式，有

$$D_T = \sum_{k=0}^{T-1} \underbrace{F_{T-1}F_{T-2}\cdots F_{k+1}}_{\text{第}k\text{ 步影响在后续闭环中传播}} B_k, \tag{3.3}$$

空乘积为单位矩阵。对于 $\hat{r}_{t+1} = r_\omega(\hat{s}_t, a_t)$，其导数为

$$\frac{d\hat{r}_{t+1}}{d\theta} = (r_{s,t} + r_{a,t}\mu_{s,t})D_t + r_{a,t}\mu_{\theta,t}.$$

于是 $\nabla_\theta \hat{J}_H$ 由这些奖励导数的折扣和构成。计算时自动微分通常按反向顺序传播向量乘积；上面的前向敏感度递推更清楚地展示了同一组依赖关系。

若单独考察一次动作干预 a_0 对最终状态的影响，并让后续控制器继续反馈，则

$$\frac{\partial \hat{s}_T}{\partial a_0} = F_{T-1} \cdots F_1 \, f_{a,0}. \tag{3.4}$$

这条式子把“起跳怎样影响落地”写成了局部影响的连乘。每一步都会重新缩放、旋转这份扰动；后面讨论的长期传播问题，直接发生在这一项中。

这些局部导数也改变了一条轨迹能够提供的优化信息。式 (2.6) 根据采样动作的 advantage 调整其概率，BPTT 则计算动作变化引起的回报变化。把问题缩为一次标量动作，设固定标准差为 $\sigma > 0$，策略参数 θ 控制动作均值，回报取线性形式：

$$a = \theta + \sigma z, \qquad z \sim \mathcal{N}(0,1), \qquad R(a) = c + ba.$$

取 $V = \mathbb{E}[R(a)] = c + b\theta$ 作为 baseline，并假设模型已准确学得斜率 b。在 PPO 更新起点，score 估计与路径求导分别给出

$$g_{\text{score}} = (R(a) - V)\nabla_\theta \log \pi_\theta(a) = (b\sigma z)\frac{z}{\sigma} = bz^2,$$
$$g_{\text{path}} = \frac{\partial R}{\partial a}\frac{\partial a}{\partial \theta} = b.$$

由 $\mathbb{E}[z^2] = 1$、$\mathbb{E}[z^4] = 3$，得到

$$\mathbb{E}[g_{\text{score}}] = \mathbb{E}[g_{\text{path}}] = b,$$
$$\mathrm{Var}(g_{\text{score}}) = 2b^2, \qquad \mathrm{Var}(g_{\text{path}}) = 0.$$

两种估计的平均方向相同；对 N 个独立 score 样本取平均，方差降为 $2b^2/N$，而这个线性例子的路径求导一次就给出方向 b。差别来自模型保存了动作与结果之间的局部关系，求导时能够直接使用这份关系。多步系统中的 BPTT 将这些局部关系沿时间连接，使一次 rollout 提供各步动作影响后续回报的方向。[14] 模型的转移和导数误差也沿这条路径进入更新，下一章将具体分析。

动力学拟合需要额外计算；给定状态、动作与物理条件后，转移规律不随采集策略改变，过去经验仍能用于监督模型。同一身体的动力学又能在不同运动与多次策略更新中复用，将拟合成本分摊到后续训练。模型内生成新转移减少了再次调用模拟器的需求，路径求导则有助于减少估计更新方向所需的 rollout。模型每一步算得多快、达到目标回报需要多少步，分别对应计算吞吐与样本利用效率；后文图 7 对这两项进行了比较。[1]

3.3 物理延迟与信用分配

上面的连乘之所以必要，是因为动作常常先改变速度，再改变位置，最后才影响跟踪误差或落地奖励。用一个简化的加速度控制系统说明：

$$q_{t+1} = q_t + hv_t, \qquad v_{t+1} = v_t + ha_t,$$

其中 h 是时间步长。保持后续动作固定，有

$$\frac{\partial q_{t+1}}{\partial a_t} = 0, \qquad \frac{\partial q_{t+2}}{\partial a_t} = h^2.$$

动作先进入速度，再进入位置。只看下一步位置奖励时，这条影响尚未到达评价变量；展开到后续位置后，链式法则就能表达它。位置对时间的二阶动力学，由多步一阶导数组织起来。

Humanoid 中的接触进一步改变作用路径。腾空时，关节内力能改变身体构型与转动分布；质心平移则由外力决定。某个关节动作对当前质心加速度的导数可以为零，却通过落地姿态影响下一次接触和后续回报。评价时域与所选状态变量，决定了当前目标能看到哪一段作用链。

于是，两条路线把长期后果传回动作的方式变得清楚了：PPO 将后续奖励汇入动作的统计价值，BPTT 将中间状态展开，并沿局部导数逐步传播。可微模型能够提供更细的方向信息；接下来要理解的是，这些方向在模型预测、长期传播和接触边界处会遇到什么困难。

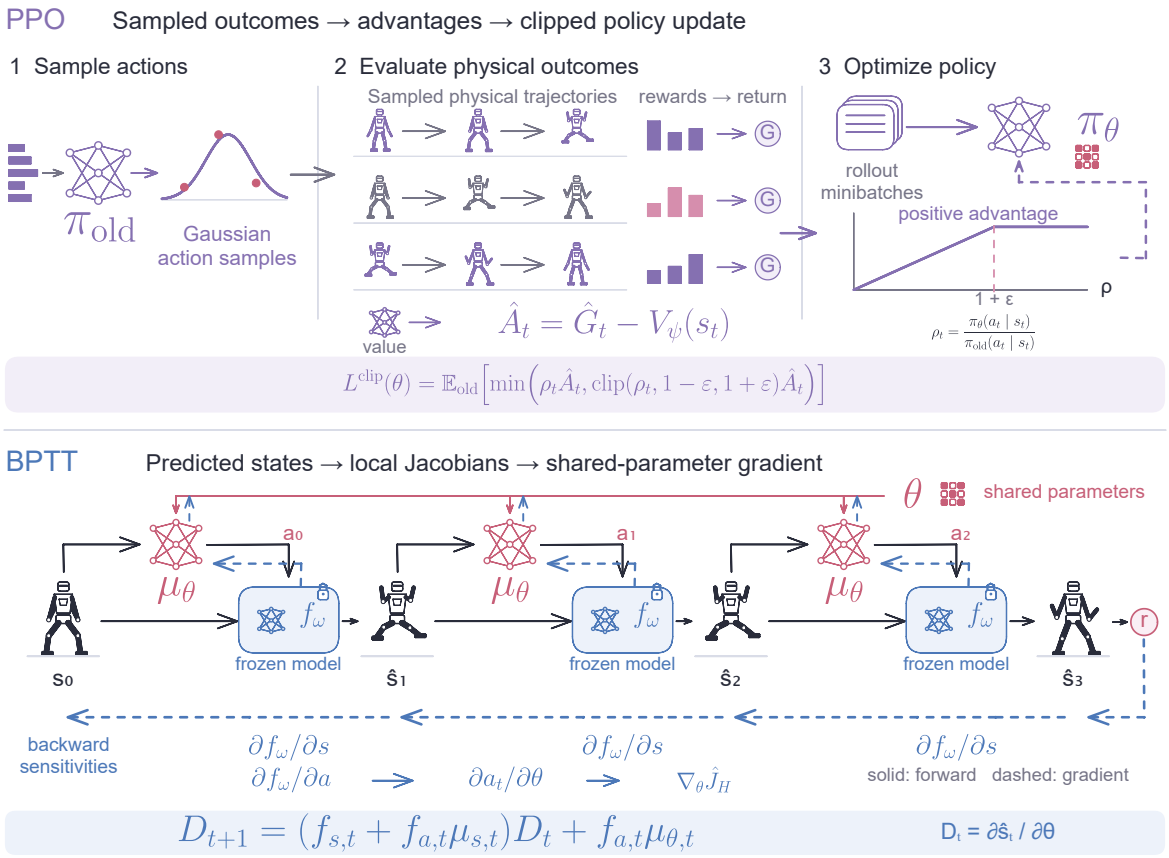


图 2 运动控制中的两种信用分配路径。上路从高斯策略采样动作，以回报减去状态价值得到 advantage，再更新 PPO 的裁剪目标；折线展示正 advantage 时的裁剪。下路以末步奖励为例，沿状态和动作分支反传梯度，各时刻的策略共享参数 θ。实线表示前向计算，虚线表示梯度。

4 BPTT 分析

BPTT 的方向来自模型给出的局部变化，再通过时间展开传到奖励。模型拟合偏差、长程 Jacobian 和接触边界，因而都会进入策略更新。沿着这条计算链逐项检查，就能理解为什么一个自然的建模思路，需要专门的训练设计才能用于控制。

4.1 模型误差与导数误差

先看模型学到了什么。动力学拟合通常是监督学习：输入 $x = (s, a, \xi)$，其中 ξ 记录摩擦等已知物理条件；目标为下一状态 $Y = s'$，平方损失训练点预测 $m(x)$。对固定输入，把条件均值记为

$\bar{y} = \mathbb{E}[Y \mid x]$，则

$$\mathbb{E}[\|Y - m\|^2 \mid x] = \mathbb{E}[\|Y - \bar{y}\|^2 \mid x] + \|m - \bar{y}\|^2. \tag{4.1}$$

交叉项为零，第一项与预测 m 无关，因此最优预测是

$$m^*(x) = \mathbb{E}[Y \mid x]. \tag{4.2}$$

因此，MSE 将输入中尚未确定的信息压缩为条件均值。若同一个输入背后混有左右两种滑动结果，均值可能位于两者中间。将这个中间状态当成实际未来再 rollout，会让下一次接触与奖励在错误位置发生。其根源可写为

$$r(\mathbb{E}[Y \mid x]) \neq \mathbb{E}[r(Y) \mid x].$$

例如 Y 以相同概率取 -1 或 1，$r(y) = y^2$；均值状态的奖励是 $r(0) = 0$，实际分布的期望奖励是 1。原本存在于分支中的结果，被点预测压到一个后续非线性计算无法正确处理的位置。

平方损失对应的统计假设也可以直接写出来。若选择固定协方差的高斯输出

$$p_\omega(Y \mid x) = \mathcal{N}(f_\omega(x), \sigma^2 I),$$

其负对数似然为

$$-\log p_\omega(Y \mid x) = \frac{\|Y - f_\omega(x)\|^2}{2\sigma^2} + C.$$

因此 MSE 与这一 Gaussian NLL 对应。连续分布还可用其他似然形式；二元终止变量则自然对应 Bernoulli 分布与 BCE。模型的状态表示和条件输入，决定了一个简单点预测需要承担多少隐藏不确定性。

这使模型输入的选择成为关键。对于给定完整状态、动作与物理参数的确定性模拟器，转移本身可以是单值映射。把已知摩擦、标定偏移等条件提供给模型，就能减少由隐藏条件混合而来的多种结果。确定这个条件关系之后，模型仍需要通过数据拟合具体的转移数值。

回到上一章的 BPTT 公式，策略更新还要使用 f_s 和 f_a。监督损失评价预测值与真实值的距离，这些 Jacobian 评价的却是邻近状态和动作怎样改变预测。两者可以有很大差异。考虑

$$f(x) = x, \qquad \hat{f}_\epsilon(x) = x + \epsilon \sin(x/\epsilon^2).$$

其函数误差满足 $|\hat{f}_\epsilon - f| \le \epsilon$，而

$$\hat{f}'_\epsilon(x) - f'(x) = \epsilon^{-1} \cos(x/\epsilon^2). \tag{4.3}$$

很小的振幅可以伴随很大的斜率。对 BPTT 来说，模型既要使轨迹落在合理位置，也要在附近给出能够引导动作改进的方向。

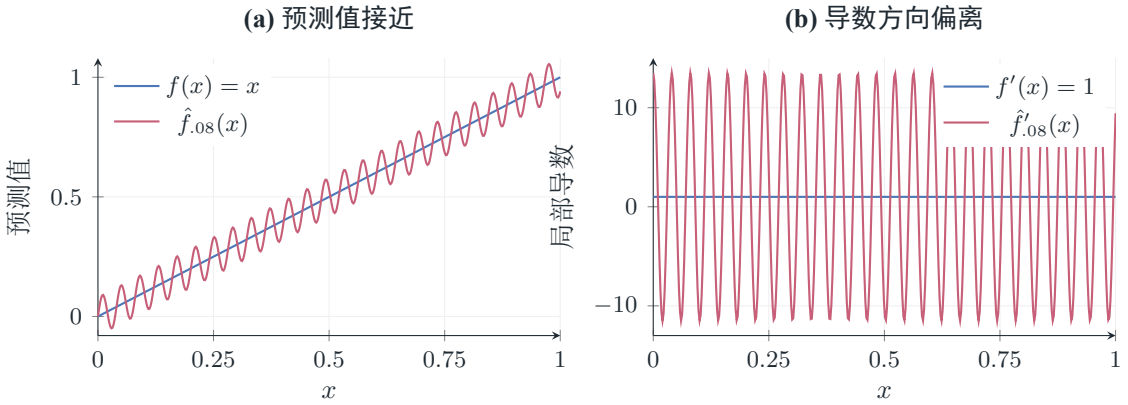


图 3 同一对函数的预测值与导数。振幅为 0.08 的预测误差，对应幅度为 12.5 的导数误差。状态损失监督数值；BPTT 使用局部变化方向。

以上误差发生在 learned model 与训练它的模拟器之间。最终让机器人执行动作时，还要把模拟器与真实身体之间的差距接上。在同一状态与动作处，令 F_{sim} 与 F_{real} 分别为模拟器与真实系统的转移，则

$$\|f_\omega - F_{\text{real}}\| \le \underbrace{\|f_\omega - F_{\text{sim}}\|}_{\text{代理模型的拟合误差}} + \underbrace{\|F_{\text{sim}} - F_{\text{real}}\|}_{\text{仿真与真实动力学的差距}}. \tag{4.4}$$

监督拟合直接处理第一项；参数辨识和真实交互数据用于修正仿真动力学，随机化训练则让策略适应一族物理条件。前面介绍的 ASAP 就在处理后一层差距。对可微 MBRL 来说，模型内优化和真机部署由这两层近似连接起来。

4.2 长程 Jacobian 与梯度传播

局部模型给出的方向，还要穿过后续许多步才能评价一次起跳或恢复动作。式 (3.4) 中的 $F_{T-1}\cdots F_1$ 正是这条传播链。其范数有上界

$$\left\|\frac{\partial \hat{s}_T}{\partial a_0}\right\| \le \left(\prod_{t=1}^{T-1}\|F_t\|\right)\|f_{a,0}\|.$$

沿某个方向反复收缩时，远期信号到达早期动作后会很弱；反复拉伸时，轨迹与导数误差也会被放大。多维系统还会持续改变敏感方向。接触使这些局部映射随状态快速变化，长展开因此同时增加计算、模型误差累积和梯度不稳定的负担。

以起跳与落地为例，起跳动作对最终成败可以有很大的因果影响。梯度计算需要在当前轨迹附近，逐步追踪这一影响怎样穿过速度、姿态、接触和后续反馈。若某一段把相关方向强烈压缩，落地的奖励就难以通过数十次局部乘积形成稳定的起跳更新；若接触处剧烈放大，更新方向又可能对微小变化异常敏感。

短展开减轻了这条链的负担，同时提出一个新的价值估计问题：窗口结束之后，当前状态还意味着多少未来收益？SHAC 用终端 critic 来回答这一问题：

$$\hat{J}_H = \mathbb{E}\left[\sum_{t=0}^{H-1}\gamma^t \hat{r}_{t+1} + \gamma^H V_\psi(\hat{s}_H)\right]. \tag{4.5}$$

其中终端项贡献的策略导数为

$$\gamma^H \underbrace{\frac{\partial V_\psi}{\partial \hat{s}_H}}_{\text{窗口外价值在终点上的斜率}} \underbrace{\frac{d\hat{s}_H}{d\theta}}_{\text{窗口内的动力学传播}}. \tag{4.6}$$

critic 把后续回报压缩为终点状态的价值函数，BPTT 的动力学链在 H 步处结束。对暂未落地的机器人，躯干朝向、角速度和脚部位置可以成为未来稳定回报的预测变量。critic 学到这些关联后，终点处的价值斜率便能引导窗口内动作。[15]

4.3 接触阈值与梯度估计

接触切换与终止还带来另一种局部问题：动作变化可以让更多样本跨过成功边界，而单条样本在边界两侧的奖励斜率都为零。用一个只有一步的任务，就能看清这种梯度信息的遗漏。考虑带高斯随机性的动作与阈值成功奖励：

$$a = \theta + \sigma z, \qquad z \sim \mathcal{N}(0,1), \qquad R(a) = \mathbf{1}\{a > b\}.$$

先从成功概率计算期望目标，可得

$$J(\theta) = \Phi\left(\frac{\theta - b}{\sigma}\right), \qquad J'(\theta) = \frac{1}{\sigma}\phi\left(\frac{\theta - b}{\sigma}\right) > 0, \tag{4.7}$$

其中 Φ, ϕ 为标准正态的 CDF 与密度。参数右移后，更多概率质量跨过成功边界，成功率随之提高。

逐条样本做普通路径求导时，阈值函数的导数几乎处处为零：

$$\mathbb{E}_z\left[\frac{dR(\theta + \sigma z)}{d\theta}\right] = 0. \tag{4.8}$$

而对动作密度求导，得到 score-function 表达式

$$\mathbb{E}_a\left[R(a)\frac{a - \theta}{\sigma^2}\right] = \frac{1}{\sigma}\phi\left(\frac{\theta - b}{\sigma}\right). \tag{4.9}$$

两种计算的差异来自硬阈值处的边界贡献：参数移动会改变跨过边界的概率质量，这部分变化在逐样本普通导数中消失了。因而，即使模型准确预测了每个动作的奖励，直接对该预测求导也可能遗漏期望目标的变化方向。Suh 等人的分析把不连续边界、陡峭接触与梯度估计质量联系起来。[16]

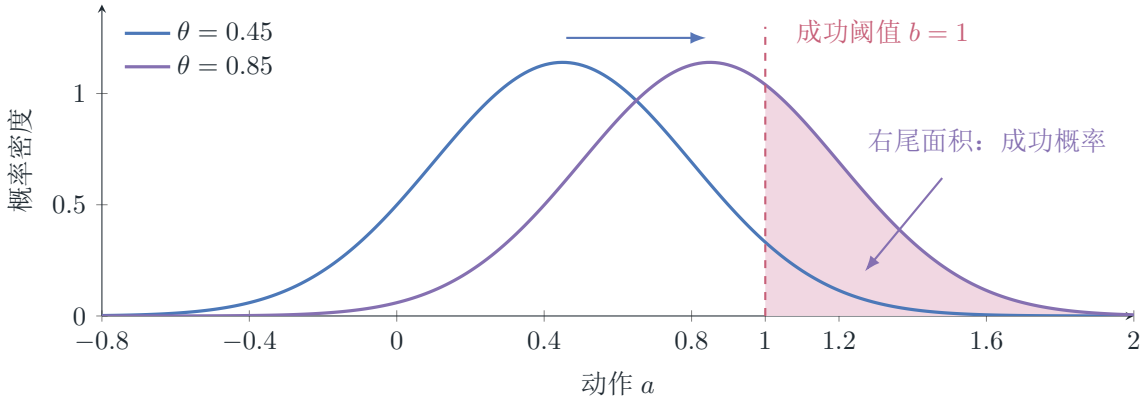


图 4 动作分布向右移动时，跨过阈值的概率质量增加。单条样本上的奖励局部斜率为零，分布层面的成功概率仍有明确的变化方向。图中 $\sigma = 0.35$。

这一差异会改变实际训练方向。加上动作代价，设 $R(a) = \mathbf{1}\{a > b\} - \beta a^2$，则

$$J'(\theta) = \frac{1}{\sigma}\phi\left(\frac{\theta - b}{\sigma}\right) - 2\beta\theta, \qquad \mathbb{E}[g_{\text{path}}] = -2\beta\theta.$$

取 $\beta > 0$、$\theta > 0$。当成功概率带来的收益超过代价时，真实目标希望加大动作；遗漏边界贡献的梯度却持续减小动作。训练可能因此停留在节省动作、无法跨过成功边界的行为上。

连续而陡峭的接触过渡呈现另一种采样困难。设 $R_\delta(a) = h((a-b)/\delta)$，则 $R'_\delta(a) = \delta^{-1}h'((a-b)/\delta)$。过渡区变窄时，落入其中的样本更少，区间内的导数却更大。有限 batch 可能长期只看到平坦区，偶尔才遇到承载大量期望的大梯度。Suh 将这类有限样本典型估计失真与 stiffness 联系起来；AHAC 则自适应调整展开时域，减少梯度穿越陡峭接触段的负担。[16, 17]

长期连乘与接触边界，对应了前作中的两条改进思路。SHAC 用终端价值表示远期回报，缩短动力学传播链；Suh 等人则根据估计质量混合路径梯度与 score 梯度，形式为 $g_\alpha = \alpha g_{\text{path}} + (1-\alpha)g_{\text{score}}$，改变梯度信息的来源。后面读到 SuperMimic 的短时 actor–critic 时，就能看到它怎样使用前一种思路。

4.4 数据覆盖与探索

以上讨论都从一条已有轨迹出发，检查沿轨迹计算出的梯度。训练还需要回答更早一步的问题：机器人有没有尝试到有用的行为，模型有没有见过相应的转移？模型的监督范围直接由数据分布确定：

$$\mathcal{L}_{\mathrm{WM}}(\omega) = \mathbb{E}_{(s,a,s')\sim\mathcal{B}}\big[\ell(f_\omega(s,a), s')\big]. \tag{4.10}$$

replay buffer $\mathcal{B}$ 决定模型见过哪些转移。若站立与正常行走样本丰富，而单脚滑动、失衡落地和迈步恢复很少，模型在后面这些区域就缺少监督。策略在模型内优化后，又会改变下一轮采集分布。模型与策略通过这个循环共同塑造可学习的行为范围。

模型内的局部优化则决定策略怎样从当前行为走向更好的行为。局部梯度描述的是当前轨迹附近的变化。迈出一大步能够恢复平衡，但当前动作附近的微调可能暂时增加能耗或跟踪误差，局部更新就难以到达这条新路径。SuperDyno 的讨论中仍将防跌倒 stepping 的发现列为困难。[10] 模型准确性、行为覆盖与局部优化在这里相互影响。

因此，数据采集也是 model-based 训练的一部分。随机动作扩大模型见过的动作邻域，参考状态重置让训练覆盖运动的不同阶段，困难片段采样增加薄弱区间的练习；critic 则把后续结果反馈给当前状态。到这里，SuperMimic 需要处理的训练环节已经逐一出现：持续补充转移、拟合可用的短时模型、用价值函数连接长期后果，再把策略带回模拟器检验和采集。

总结以上讨论，可微 MBRL 的主要性质有以下三点：

1. **动力学复用与样本效率。**同一套身体动力学可服务多种动作和多次策略更新；模型导数直接提供动作改进方向，提高交互数据与 imagined rollouts 的利用效率。
2. **数据覆盖与探索。**探索不足会使关键状态和动作缺少模型监督；模型内的局部梯度更新，也较难发现远离当前行为的新动作。
3. **梯度质量与估计偏差。**模型及其导数的误差会影响更新方向，长程连乘可能导致梯度消失或爆炸；硬阈值处，逐样本求导可能遗漏跨边界的概率质量变化，产生有偏估计。

5 SuperMimic

前面的推导说明，可微动力学通过模型导数提供动作的优化方向，模型的训练范围、预测误差和梯度传播长度都会影响这个方向。SuperMimic 围绕这些问题组织训练：策略持续回到模拟器采集数据，模型在短窗口内接受多步预测监督，actor 在较短的动力学链上改进动作，窗口外的收益交给 critic。

5.1 交替训练与经验回放

策略在训练中会从站立走向跑跳，也会进入失衡和落地状态。模型需要不断获得这些新区域的转移，才能继续为策略提供有用的后果预测。SuperMimic 让策略、世界模型与 critic 在同一个循环中交替改进，三组参数分别记为 θ, ω, ψ。物理状态 s_t 产生本体感知观测 o_t；目标 g_t 默认来自参考运动，也可对应其他目标接口。确定性 actor 根据观测与目标输出归一化关节设定值：

$$a_t = \pi_\theta(o_t, g_t).$$

actor 决定下一轮会访问哪些状态，模型学习这些状态中的动作后果，critic 估计继续控制的长期回报。三者通过图 5 中的数据循环连接起来。[1, §3]

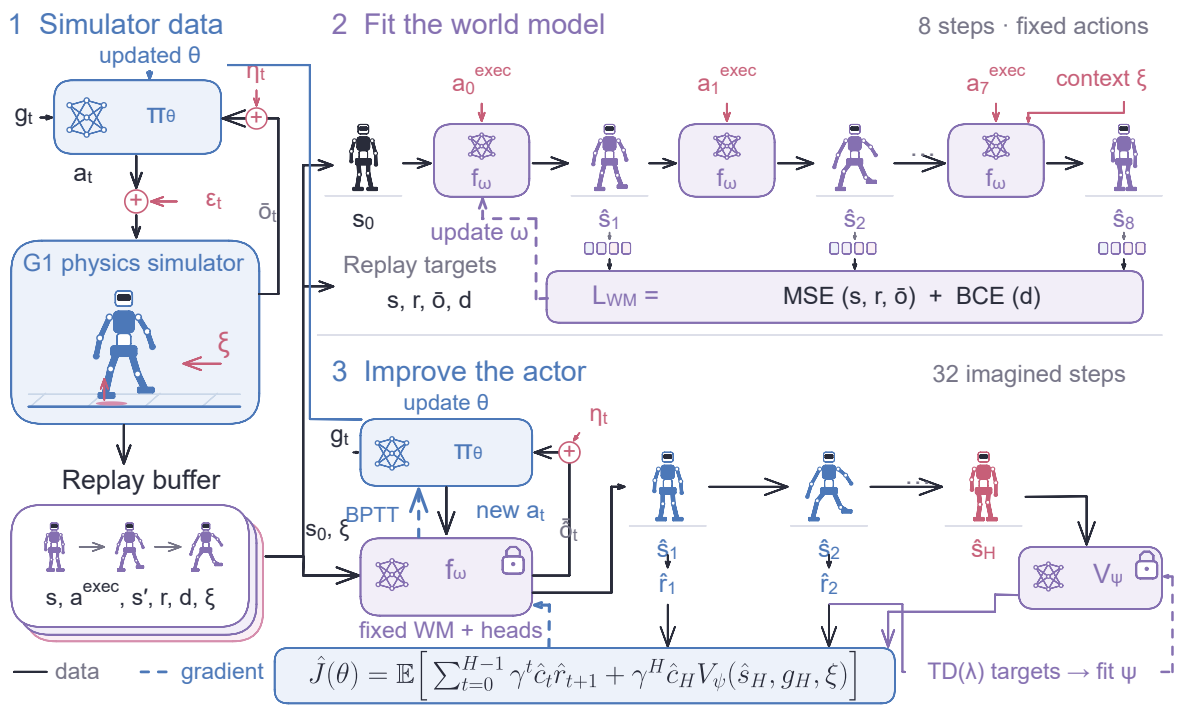


图 5 SuperMimic 的交替训练。模型拟合沿日志动作展开，策略改进沿当前 actor 的新动作展开；两者从 replay 中获得真实模拟器状态。实线承载数据，虚线表示参数更新：模型拟合更新 ω，actor 通过冻结的世界模型和终点价值更新 θ，critic 用 TD(λ) 标签拟合 ψ。

每轮先让当前 actor 在物理模拟器中采集转移。执行动作可加入噪声 $a_t^{\text{exec}} = a_t + \epsilon_t$，replay buffer 记录实际执行的 a_t^{exec} 及其后果，供模型拟合使用。随后，从记录状态启动 imagined rollout，让当前 actor 在模型中产生新动作、得到奖励，再通过冻结的模型优化 actor，并拟合 critic。更新后的策略返回模拟器，补充它现在会遇到的状态与动作。

replay 同时保留较早的经验。给定状态、执行动作与物理条件后，历史策略和当前策略遵循同一转移规律，因而旧数据仍可用于动力学监督；新的数据则把模型拟合带到策略正在扩展的区域。这一 Dyna 风格的交替过程，将模型的数据覆盖与策略改进放在了同一条反馈链中。[18]

5.2 世界模型与多步监督

数据进入 buffer 之后，接下来的问题是模型怎样学会连续使用自己的预测。单步误差会改变第二步的输入，并继续影响后续接触与姿态；模型训练也需要看到这条累积过程。为支持完整的控制 rollout，世界模型提供动力学、奖励、观测和终止四个接口：

$$\hat{s}_{t+1} = f_\omega(\hat{s}_t, a_t, \xi), \qquad \hat{r}_{t+1} = r_\omega(\hat{s}_t, a_t, g_t),$$
$$\hat{o}_t = g_\omega(\hat{s}_t, \xi), \qquad \hat{d}_t = d_\omega(\hat{s}_t, g_t).$$

其中 ξ 是每个 episode 的物理上下文，包含摩擦、关节标定偏移和躯干质心偏移。同样的姿态与动作在不同摩擦下会产生不同后果；将已知的 ξ 输入模型，就能按条件拟合这些转移。能够从状态解析计算的 head 直接计算，其余 head 学习预测。

设 replay 窗口为 $(s_0, a_0, s_1, \ldots, a_7, s_8)$。模型从 $\hat{s}_0 = s_0$ 开始，后续状态全部由自身预测：

$$\hat{s}_1 = f_\omega(s_0, a_0, \xi), \quad \hat{s}_2 = f_\omega(\hat{s}_1, a_1, \xi), \quad \ldots, \quad \hat{s}_8 = f_\omega(\hat{s}_7, a_7, \xi).$$

动作沿日志固定，状态则自回归。后面各步的误差因此也会训练前面的预测，让模型学会从自身产生的输入继续推进。拟合目标为

$$\mathcal{L}_{\text{WM}}(\omega) = \mathbb{E}_{\mathcal{B}} \sum_{j=1}^{8} \Big[\|\hat{s}_j - s_j\|^2 + (\hat{r}_j - r_j)^2 + \|\hat{\bar{o}}_j - \bar{o}_j\|^2 + \text{BCE}(\hat{d}_j, d_j) \Big]. \tag{5.1}$$

解析 head 对应的损失项省去。连续状态、奖励和无噪观测用数值回归，终止标签用二元交叉熵。这里的 $k = 8$ 规定模型接受监督的日志窗口；后面的 $H = 32$ 则规定 actor 使用模型获取梯度的长度。前者让训练暴露多步预测偏差，后者决定一次策略更新要穿过多长的动力学链。

传感器噪声承担另一项工作：让 actor 习惯实际反馈中的扰动。模拟器中已知其采样方式，因而可以把它从动力学拟合中分开：

$$o_t = \bar{o}_t + \eta_t, \qquad \hat{o}_t = \hat{\bar{o}}_t + \eta_t. \tag{5.2}$$

模型先预测无噪观测，再在外部采样传感噪声送给 actor。这样，物理变化通过 ξ 进入转移条件，传感变化通过 η_t 进入控制器输入。模型集中拟合给定条件下的身体转移，actor 则学习根据带噪反馈持续控制。

5.3 短时展开与终点价值

有了多步模型，策略优化仍要面对长程 Jacobian 的连乘。SuperMimic 在每次更新中只显式展开一段短轨迹，并由终端 critic 接续未来回报。展开从 replay 状态和对应 ξ 出发，每一步接收加入噪声后的预测观测。模型参数 ω 在本轮 actor 更新中固定，状态与动作 Jacobian 继续参与反向传播。

短窗口还可能穿过失败边界。先用累计生存权重表达终止后的奖励关闭。模拟器日志中的 $d_j \in \{0, 1\}$，累计生存权重定义为

$$c_0 = 1, \qquad c_{t+1} = c_t(1 - d_{t+1}), \qquad c_t = \prod_{j=1}^{t} (1 - d_j). \tag{5.3}$$

在模型 rollout 中，将二值 d_j 换成预测概率 $\hat{d}_j \in [0, 1]$，代入同一递推，得到连续的生存权重 $\hat{c}_t$。由此，终止风险可以随状态变化进入想象回报及其梯度。真实模拟目标写为 $J = \mathbb{E} \sum_{t \geq 0} \gamma^t c_t r_{t+1}$；模型内的 actor 目标则为

$$\hat{J}(\theta) = \mathbb{E}\Big[\sum_{t=0}^{H-1} \gamma^t \hat{c}_t \hat{r}_{t+1} + \gamma^H \hat{c}_H V_\psi(\hat{s}_H, g_H, \xi) \Big], \tag{5.4}$$

默认 $H = 32$，控制频率为 50 Hz，对应 0.64 秒。蓝色项通过窗口内的动力学计算奖励，紫色项由 V_ψ 预测窗口之后的累计回报。actor 因而能通过终点价值学习更远的后果，同时将显式动力学反传控制在三十二步内；生存权重则使两部分都计入终止风险。

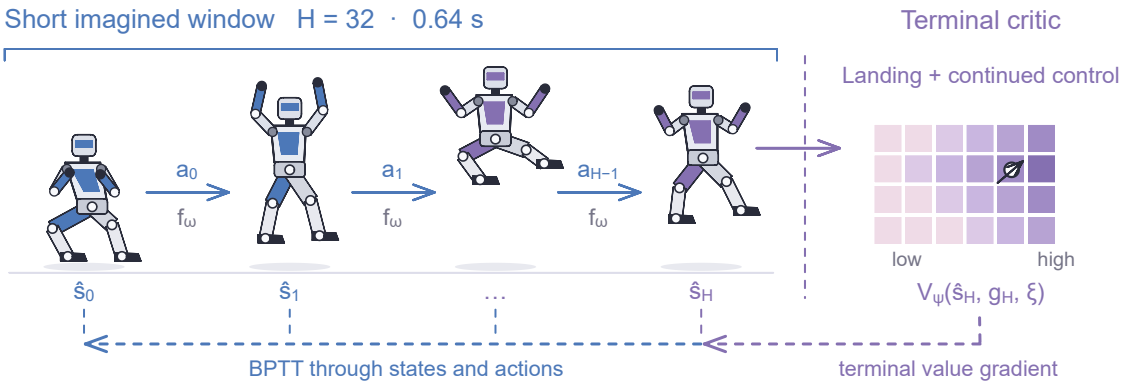


图 6 critic 将更远的未来压缩到窗口终点。actor 使用 $\partial V_\psi/\partial s_H$，再沿窗口内的模型链更新动作。

对起跳动作而言，窗口结束时机器人可能还在腾空。终点处的姿态与角速度已经包含落地线索，critic 要把这些线索映射为后续回报，形成图中返回窗口的价值梯度。参考运动描述希望跟踪的目标，critic 则评价从当前实际状态继续控制的结果；暂时接近参考、随后难以恢复的姿态，也会通过后续回报影响价值。

5.4 终止风险与生存权重

前章的阈值例子显示，对硬阈值逐样本做普通求导，会遗漏概率质量跨越边界的贡献。在 SuperMimic 的 imagined objective 中，连续终止头让“还能获得多少未来回报”随预测终止概率改变。令窗口内递推回报为

$$U_H = V_\psi(\hat{s}_H, g_H, \xi), \qquad U_t = \hat{r}_{t+1} + \gamma(1-\hat{d}_{t+1})U_{t+1}.$$

展开 U_0 就得到式 (5.4) 中的单条轨迹目标。求导后出现三项：

$$\frac{dU_t}{d\theta} = \frac{d\hat{r}_{t+1}}{d\theta} + \gamma(1-\hat{d}_{t+1})\frac{dU_{t+1}}{d\theta} - \gamma U_{t+1}\frac{d\hat{d}_{t+1}}{d\theta}. \tag{5.5}$$

最后一项按后续价值 U_{t+1} 衡量终止概率变化的影响：后续价值为正时，提高终止概率会降低目标。连续终止头因此把接近失败边界所损失的未来收益纳入模型梯度。转移到终止状态的当次奖励仍乘此前的 c_t，终止后的奖励才由后续权重关闭。

终止头提供延续风险的导数，learned dynamics 提供接触与运动后果的导数。再加上每一步的跟踪奖励，actor 在尚未完成整段动作时，也能从姿态误差与未来收益中获得更新方向。这些代理随模拟器数据持续拟合，并在短窗口内用于策略优化。

5.5 Critic 与多步回报

终点价值怎样学到落地与恢复的收益，取决于它接受的训练标签。SuperMimic 从 imagined transitions 中向后计算多步 return，把窗口内的奖励与更远的价值估计结合起来。记 $V_t = V_\psi(\hat{s}_t, g_t, \xi)$、$m_{t+1} = 1-\hat{d}_{t+1}$，论文使用 λ-return：

$$\hat{R}_t = \hat{r}_{t+1} + \gamma m_{t+1}\left[(1-\lambda)V_{t+1} + \lambda\hat{R}_{t+1}\right], \quad \hat{R}_H = V_H. \tag{5.6}$$

取 $\lambda = 0$ 时，下一状态价值直接构成一步 bootstrap；取 $\lambda = 1$ 时，奖励沿窗口累积到末端，再用 V_H 接续。中间取值将不同长度的标签混合起来。默认 $\gamma = 0.99, \lambda = 0.95$。

这组多步 return 还与 PPO 常用的广义优势估计（GAE）相连。令 $\delta_t = \hat{r}_{t+1} + \gamma m_{t+1} V_{t+1} - V_t$，则

$$\hat{R}_t - V_t = \delta_t + \gamma\lambda m_{t+1}(\hat{R}_{t+1} - V_{t+1}).$$

继续展开，得到

$$\hat{R}_t - V_t = \sum_{l=0}^{H-t-1} (\gamma\lambda)^l \left(\prod_{i=1}^{l} m_{t+i} \right) \delta_{t+l}. \tag{5.7}$$

右侧按时间与生存权重加权的逐步 TD 误差给出 $\hat{R}_t - V_t$，即多步优势估计；加回 V_t，就得到 critic 拟合的 return 标签 $\hat{R}_t$。SuperMimic 据此拟合

$$\mathcal{L}_V(\psi) = \mathbb{E} \sum_{t=0}^{H-1} \left[V_\psi(\hat{s}_t, g_t, \xi) - \mathrm{sg}(\hat{R}_t) \right]^2. \tag{5.8}$$

其中 sg 表示本轮拟合中固定的目标。标签每次 rollout 计算一次，用来更新 critic 参数；actor 更新时固定 ψ，保留价值对终点状态的导数。多步 return 负责把后续奖励带入价值标签，BPTT 再沿这个价值的斜率改进窗口内动作。[13, 15, 1]

5.6 数据采样与部署接口

模型与价值都要从访问过的状态中学习，因而最后还要回到前章的覆盖问题。参考动作提供了起跳、转体与落地的时间结构，密集奖励逐步衡量跟踪误差；训练采样则决定哪些阶段获得多少练习。SuperMimic 把动作时间轴按一秒分 bin，维护每个 bin 的回报 G_b，当前困难分布写为

$$q_{\text{hard}}(b) \propto \exp\left(-25 \frac{G_b}{G_{\max}} \right).$$

reset 由 50% 均匀采样、40% 当前困难分布和 10% 历史困难分布混合。若一段翻转已经能起跳，却经常在落地前失败，较低的局部回报会增加这一时段的练习机会；均匀项维持整库覆盖，历史项保留对曾经困难片段的练习。模型 imagination 再从 replay 抽取起点，把这些模拟器实际访问过的状态用于短窗口优化。

时间轴采样增加不同阶段的覆盖，采集期动作噪声则增加同一状态附近的动作覆盖，默认 $\epsilon_t \sim \mathcal{N}(0, 0.1^2 I)$。这些实际执行的带噪动作进入模型监督，actor 则沿当前确定性策略的想象轨迹反传。

这套数据与模型循环还需要接到真机可获得的输入。模型和 critic 在训练时可使用完整状态与 ξ，actor 使用最近十帧本体感知和未来十帧参考。物理随机化覆盖摩擦、关节偏移与质心偏移；传感噪声覆盖关节位置、速度、IMU 角速度和投影重力。前者让策略面对不同身体与接触参数，后者让策略适应反馈扰动；训练中可读取的特权信息留在模型与 critic 一侧。

策略输出转换为关节设定值 $q^{\text{sp}} = \alpha a + q^0$，再由低层 PD 执行。真机控制路径运行 actor 与关节控制器，world model 和 critic 承担训练计算。论文使用平地模拟环境，并去掉了训练期突发 root-velocity pushes：这类未作为输入记录的状态跳变会干扰确定性转移拟合。推扰恢复随后在独立测试中评价。

至此，前章的几条困难都有了具体的处理位置：replay 循环与多步拟合追踪模型误差，短展开与 critic 缩短动力学梯度链，连续生存权重表达终止风险，参考、重置与动作噪声改变数据覆盖。下一步需要看实验：这些设计是否减少了训练计算，critic 是否改变了窗口之外的行为，以及同一个模型在动作库扩大后是否仍然有用。

6 效果

6.1 训练效率与动作规模

在大动作库上，SuperMimic 使用 264.56 小时公共动作数据，在单张 H100 上运行完整训练循环三小时后，normalized return 超过 SONIC 已发布的 checkpoint。SONIC 报告的训练配置是 611 小时数据、128 张 L40、168 小时；论文的千倍 GPU-hours 结论对应这组系统比较。两张 H100 训练 9.8 小时后，SuperMimic 在统一终止条件下评价的 129,514 条训练动作中达到零失败。[1, §4.1, App. F] 这里的 normalized return 将未折扣奖励和按完整参考片段的最大奖励和归一化，提前终止会降低分数。

同一 H100 上，模型在实际使用的 2k–16k 并行规模内，rollout 吞吐比 MuJoCo Warp 高十倍以上。在相同 learned world model 内，analytic update 用约 1/64 的 imagined steps 达到 PPO-WM 的最佳训练回报，见图 7。动作库从 1 小时扩展到约 264 小时后，归一化的八步状态预测误差仍保持在 0.007–0.011 区间。[1, §4.2, Fig. 3]

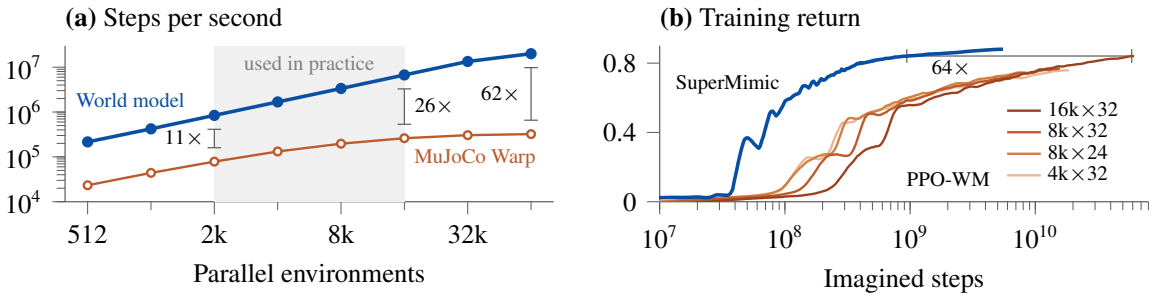


图 7 原论文图 5。左：H100 上模型与模拟器的前向吞吐。右：walk/run/sprint 的模型内训练，比较 analytic update 与不同 batch 的 PPO-WM。

6.2 时域消融与推扰恢复

图 8 给出了相同任务设置下的 PPO-Sim 对照与时域消融。SuperMimic 约 1.2 小时达到 0.82 evaluation return，PPO-Sim 在十八小时预算内未达到该值。$H = 16$ 时，无 critic 的版本达不到目标回报；加入 critic 后，能达到无 critic、$H = 32$ 的水平。默认 $H = 32$ 配合 critic 最快达到目标，继续加长窗口反而使训练变慢。[1, §4.3]

两种策略达到相近的正常跟踪回报后，论文对静态 T-pose 施加 0.5–4 m/s 的速度扰动。有 critic 的策略在 0.5–2.4 秒内稳定；无 critic 的策略在 0.5 m/s 扰动后持续踉跄，在 4 m/s 时跌倒。[1, §4.3]

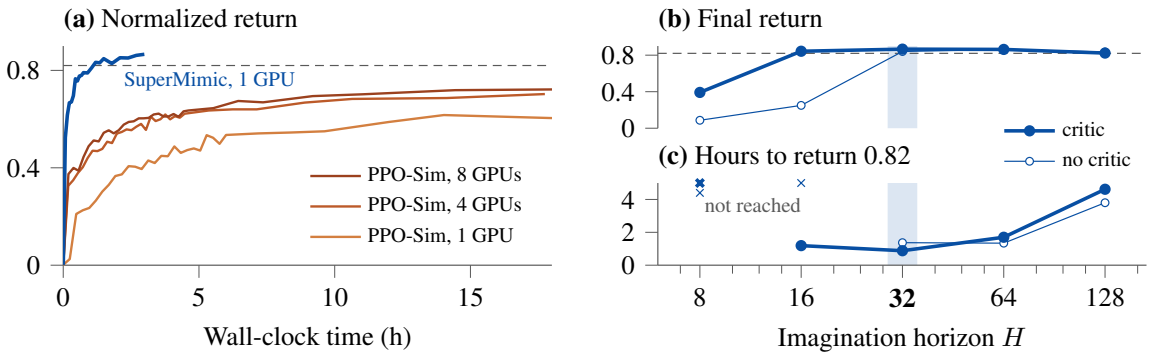


图 8 原论文图 4。左：LAFAN1 的相同动作、观测、奖励、随机化与网络规模下的 PPO-Sim 对照。右：critic 与展开长度消融，叉号表示未达到目标。

6.3 G1 实机控制

训练后的同一个跟踪器在真实 G1 上执行了跳步、侧滚、90° 翻转和原地 360° 翻转，未进行逐动作调参。部署时运行 actor 与低层关节控制器，world model 和 critic 留在训练环节。[1, §4.4]



图 9 原论文图 6 的完整动作序列。自上而下为跳步、侧滚、90° 翻转和原地 360° 翻转。

7 复现

本轮采用第三方实现 Uni-SuperMimic，在单张 H100 80GB 上训练 G1 仿真跟踪策略，动作库为 LAFAN1 的 40 条运动，参考时长约 2.45 小时。使用 4096 个并行环境训练 12000 轮，总用时约 **4 小时 19 分钟**。训练后对参考库逐条从第 0 帧开始、关闭观测与动作噪声进行完整评测，**40/40 条动作全部完成**，平均归一化整段回报为 **0.833**。

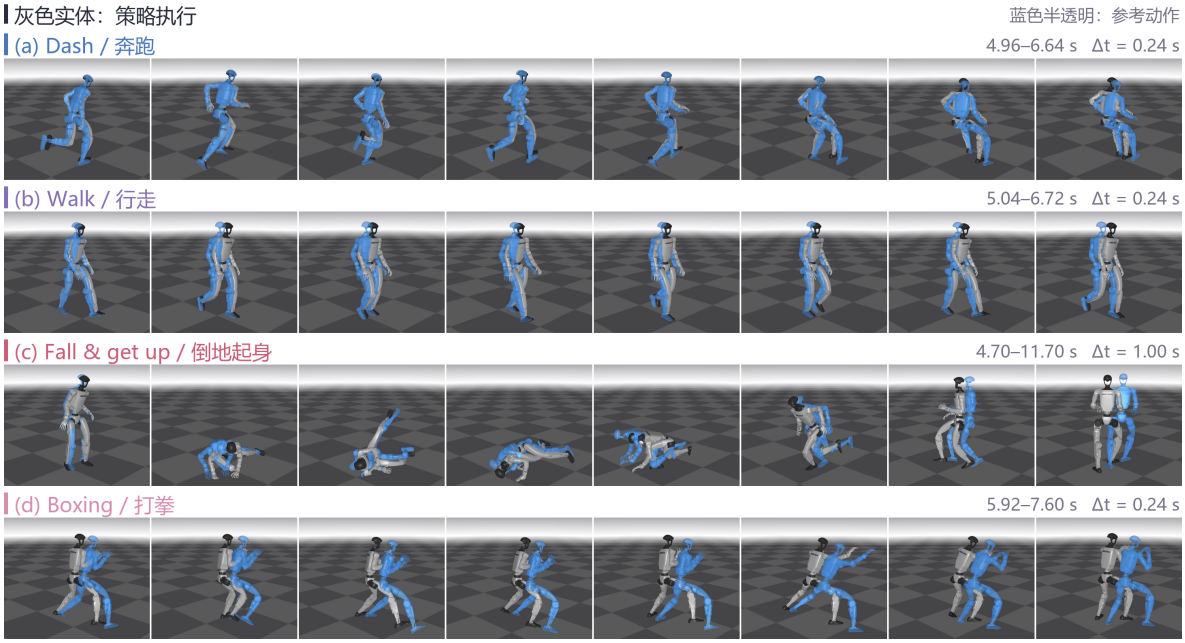


图 10 本轮策略在 MuJoCo 中的动作回放。每行八帧，自上而下为奔跑、行走、倒地起身和打拳；灰色实体为策略执行，蓝色半透明为参考动作。

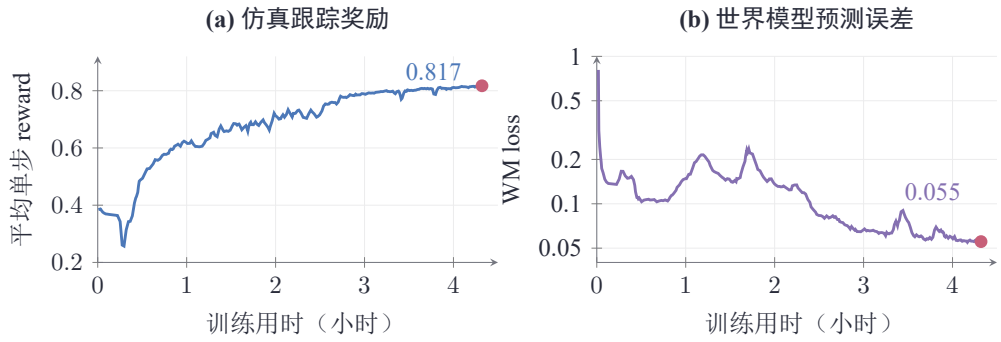


图 11 本轮复现的训练曲线。左：物理仿真中的平均单步跟踪奖励。右：world model 的多步预测损失，纵轴为对数。数据来自原始训练日志，每 50 轮记录一次。

8 Action World 与 WAM

SuperMimic 把动作条件化的身体动力学学得相当好，并将它反复用于控制器训练。这里的 world 主要是同一 humanoid 身体在平地上的姿态、速度与接触变化；增加运动，主要扩大这套动力学的访问范围。[1, §6, App. E]

当 World Action Model（WAM）走向物体操作，动作后果还会随对象和场景改变：拉抽屉要考虑导轨，拿杯子要考虑支撑与倾倒，视觉又可能遮住接触状态。我们期待看到，WAM 在物体、约束和场景都更复杂时，怎样学到可复用的动作后果，并真正用这些预测改善控制。

A 符号与训练接口

符号	含义
$s_t, \hat{s}_t$	模拟器物理状态与模型预测状态。
$o_t, \bar{o}_t$	actor 的观测与无噪观测；$o_t = \bar{o}_t + \eta_t$。
g_t, a_t	目标条件与归一化关节设定值。
r_{t+1}, d_{t+1}	执行动作后的奖励与到达状态的终止标签。
θ, ω, ψ	actor、world model、critic 的可学习参数。
ξ, η_t, ϵ_t	episode 物理上下文、观测噪声与采集期动作噪声。
D_t, F_t, B_t	状态对策略参数的总导数、闭环状态 Jacobian、本步参数注入项。
$c_t, \hat{c}_t$	真实与想象轨迹中的累计生存权重。
k, H, γ, λ	模型拟合窗口、策略想象窗口、折扣与 return 混合系数。

表 1 正文使用的主要符号。

项目	SuperMimic 默认配置
模型监督窗口 / 策略窗口	$k = 8$ / $H = 32$，控制步长 20 ms
折扣 / λ-return	$\gamma = 0.99$，$\lambda = 0.95$
模型网络	MLP，三层、每层 2048 单元
actor 观测 / 运动条件	最近十帧本体感知 / 未来十帧参考运动
策略批次	4096 个并行 imagined rollouts
每轮模型拟合	十个 batch，每 batch 2048 个 replay 窗口
critic 拟合	五个 epoch，每个 epoch 四个 minibatch
replay 容量	每个环境最近 1000 个控制步
actor 梯度处理	全局 norm 裁剪至 1.0，再逐元素裁剪至 $[-0.1, 0.1]$
采集动作噪声	$\mathcal{N}(0, 0.1^2 I)$

表 2 对应原论文 Appendix A 与 D。actor 的梯度裁剪作用于 BPTT 导数；PPO clip 作用于式 (2.8) 的概率比收益。

类别	变量	均匀采样范围
物理上下文 ξ	摩擦系数	$[0.3, 1.2]$
	关节标定偏移	± 0.01 rad
	躯干质心偏移	x : ± 0.025 m；y, z : ± 0.05 m
观测噪声 η_t	关节角 / 关节速度	± 0.01 rad / ± 0.5 rad/s
	IMU 角速度	± 0.2 rad/s
	投影重力	每维 ± 0.05

表 3 模型条件与 actor 输入扰动的具体取值。物理上下文逐 episode 采样；观测噪声在 world model 外加入。

参考文献

[1] Qiayuan Liao, Yiyang Shao, Junfeng Long, et al. SuperMimic: Scaling Humanoid Whole-Body Control with One Differentiable World Model. CoRL, 2026. 项目：`https://supermimic.github.io/`.

[2] Xue Bin Peng, Pieter Abbeel, Sergey Levine, Michiel van de Panne. DeepMimic: Example-Guided Deep Reinforcement Learning of Physics-Based Character Skills. ACM TOG, 2018.

[3] Nikita Rudin, David Hoeller, Philipp Reist, Marco Hutter. Learning to Walk in Minutes Using Massively Parallel Deep Reinforcement Learning. CoRL 2021; PMLR 164, 2022.

[4] Tairan He, Zhengyi Luo, Wenli Xiao, et al. Learning Human-to-Humanoid Real-Time Whole-Body Teleoperation. IROS, 2024.

[5] Tairan He, Jiawei Gao, Wenli Xiao, et al. ASAP: Aligning Simulation and Real-World Physics for Learning Agile Humanoid Whole-Body Skills. RSS, 2025.

[6] Yitang Li, Yuanhang Zhang, Wenli Xiao, et al. Hold My Beer: Learning Gentle Humanoid Locomotion and End-Effector Stabilization Control. 2025.

[7] Qiayuan Liao, Takara E. Truong, Xiaoyu Huang, Yuman Gao, Guy Tevet, Koushil Sreenath, C. Karen Liu. BeyondMimic: From Motion Tracking to Versatile Humanoid Control via Guided Diffusion. arXiv:2508.08241v4, 2025.

[8] Zhengyi Luo, Ye Yuan, Tingwu Wang, et al. SONIC: Supersizing Motion Tracking for Natural Humanoid Whole-Body Control. Science Robotics 11(117):eaed4592, 2026; arXiv:2511.07820v4.

[9] Levi Fussell, Kevin Bergamin, Daniel Holden. SuperTrack: Motion Tracking for Physically Simulated Characters using Supervised Learning. ACM TOG 40(6), 2021.

[10] Yu Lei, Zhengyi Luo, Tairan He, Jinkun Cao, Guanya Shi, Kris Kitani. Scalable Humanoid Whole-Body Control via Differentiable Neural Network Dynamics. ICLR Workshop on World Models, 2025.

[11] John Schulman, Sergey Levine, Philipp Moritz, Michael I. Jordan, Pieter Abbeel. Trust Region Policy Optimization. ICML, 2015.

[12] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, Oleg Klimov. Proximal Policy Optimization Algorithms. 2017.

[13] John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, Pieter Abbeel. High-Dimensional Continuous Control Using Generalized Advantage Estimation. ICLR, 2016.

[14] Nicolas Heess, Gregory Wayne, David Silver, Timothy Lillicrap, Tom Erez, Yuval Tassa. Learning Continuous Control Policies by Stochastic Value Gradients. NeurIPS, 2015.

[15] Jie Xu, Viktor Makoviychuk, Yashraj Narang, Fabio Ramos, Wojciech Matusik, Animesh Garg, Miles Macklin. Accelerated Policy Learning with Parallel Differentiable Simulation. ICLR, 2022.

[16] Hyung Ju Suh, Max Simchowitz, Kaiqing Zhang, Russ Tedrake. Do Differentiable Simulators Give Better Policy Gradients? ICML, PMLR 162:20668–20696, 2022.

[17] Ignat Georgiev, Krishnan Srinivasan, Jie Xu, Eric Heiden, Animesh Garg. Adaptive Horizon Actor-Critic for Policy Learning in Contact-Rich Differentiable Simulation. 2024.

[18] Richard S. Sutton. Dyna, an Integrated Architecture for Learning, Planning, and Reacting. SIGART Bulletin 2(4):160–163, 1991.